主流广告 DSP 的
出价策略与预算分配算法

技术综述

需求方平台 · 实时竞价 · Bid Shading · 强化学习

2026 年 10 月

学术文献重推 + 工业界公开材料交叉核对 + 数值仿真验证

Contents

主流广告 DSP 的出价策略与预算分配算法 2
摘要 2
目录 3
第 1 章 问题的统一形式 3
第 2 章 出价公式：从对偶到实践 4
第 3 章 一价时代的 Bid Shading 6
第 4 章 预算平滑与双约束协同 8
第 5 章 学习型出价：RL 与生成式 9
第 6 章 工业界实际部署图景 10
第 7 章 主流方案的共性判断 11
第 8 章 前沿与未解问题 12
附录 A 复现说明 12
附录 B 算法速查 13
附录 C 术语中英对照 13
参考文献（核心 20 条） 14
说明 15

主流广告 DSP 的出价策略与预算分配算法

技术综述 | 2026-10-26 | 对象：需求方平台（Demand-Side Platform）在实时竞价中的出价决策 方法：学术文献重推 + 工业界公开材料交叉核对 + 小规模数值仿真验证（全部实验附可复现口径）

摘要

广告 DSP 的核心问题可以用一句话概括：在不知道未来会到来哪些流量、也不知道竞争对手会出多少价的情况下，如何为每一条流量实时出一个数，使整个投放周期内的营销目标最大化、同时不突破预算与成本约束。

本报告的核心判断有五条：

1. 今天的工业界主流不是某一种“算法”，而是“统一的受约束最优化骨架 + 多套求解器”。几乎所有主流平台把问题写成同一个线性规划（LP）形式，通过对偶变换得到一个出价公式，真正需要在线估计的只有少数几个对偶变量。Google、阿里妈妈、Facebook 的公开材料在这一点上高度一致。这不是巧合，而是 LP 对偶结构的必然结果。

2. 出价公式几乎是同一族：$b_j = \dfrac{v_j + \sum_c \alpha_c w_j^c}{\lambda + \sum_c \alpha_c}$。 预算约束与 tCPA/tROAS 约束的差别，只体现在 w_j^c 与 α_c 的取法上。我做了数值验证：用该公式求得的解与“贪心地按性价比截断”的 LP 最优解完全一致（价值比 1.0000）。

3. 一价拍卖已经彻底取代二价，Bid Shading 从“可选优化”变成“必需组件”。 行业口径显示约 96% 的程序化请求以一价成交（2022 年为 88%）。在一价下“按价值出价”是明显次优的，DSP 必须同时估计“我值多少”和“我需要出多少才赢”。Bid Shading 因此从独立模块下沉为出价链路的标准环节。

4. 预算平滑（pacing）的技术路线已经从 PID 走向“对偶变量的学习型调节”，并在 2019 年后大规模转向强化学习与生成式模型。 阿里妈妈公开的演进路线是四代：经典控制（PID）→ 规划求解（LP/Online-LP）→ 强化学习（仿真/离线/在线）→ 生成式（AIGB）。其中 AIGB 发表于 KDD 2024，并在线上 AB 中报告 GMV +4.2%、ROI +5.6%。

5. 2024—2026 的真正变化不在公式，而在“谁来决策”。 三大平台都在把出价决策进一步封装进代理（agent）：Google 的 Ads Advisor、Meta 的 Advantage+、The Trade Desk 的 Koa。但值得注意的是：没有一家把“完全无人监督的自主出价”作为默认。这提示一个判断——出价算法本身已相对成熟，瓶颈转移到了可解释性、增量性与信任。

关键词：需求方平台；实时竞价；自动出价；对偶最优；Bid Shading；预算平滑；强化学习；生成式出价

目录

章	标题	主要内容
第 1 章	问题的统一形式	DSP 的决策变量、目标、约束；为什么它必然是一个 LP
第 2 章	出价公式：从对偶到实践	统一出价公式的推导、特例、数值验证、工程调参
第 3 章	一价时代的 Bid Shading	一价为何改变一切、shading 的算法谱系、先验无关策略
第 4 章	预算平滑与双约束协同	PID → 对偶梯度 → 多约束协调；一个常见误区
第 5 章	学习型出价：RL 与生成式	USCB、离线 RL、SORL、AIGB；四代演进与证据分级
第 6 章	工业界实际部署图景	Google / Meta / TTD / 阿里妈妈 / 第三方；能力矩阵
第 7 章	主流方案的共性判断	七条可操作的工程结论
第 8 章	前沿与未解问题	隐私、Agentic、增量性、多通道、公平性
附录	复现说明与速查	仿真口径、算法速查、术语中英对照

第 1 章 问题的统一形式

1.1 DSP 到底在决策什么

一条广告请求到达时，DSP 必须在毫秒级完成三件事：判断这条流量对该广告主值多少钱、决定出多少价、以及判断这个钱该不该花（预算与成本约束）。三者耦合在一起。

设一个投放周期内有 m 次竞价机会，索引 j。对每次机会：

- v_j：该流量的价值（通常由 eCPM 预测模型给出，如 点击率×转化率×客单价）；
- p_j：竞争价格（其他买家的最高报价或结算价，未知）；
- $x_j \in [0,1]$：是否赢得（决策变量）。

DSP 面临两类约束：预算约束 $\sum_j p_j x_j \le B$，以及成本约束（tCPA / tROAS / ROI）。Gagan Aggarwal 等 24 位 Google 研究者在 2024 年的综述里把这一切统一成如下规划（下称“出价问题”）[1]：

$$\max_{\{x_j\}} \sum_j (v_j x_j - \lambda\, p_j x_j) \quad \text{s.t.} \quad \sum_j p_j x_j \le B, \qquad \sum_j v_j x_j \ge \tau \sum_j p_j x_j.$$

其中 $\lambda \in [0,1]$ 控制“价值最大化”还是“效用最大化”：

- $\lambda = 0$：价值最大化（只在乎拿到多少转化，不在乎花多少钱）——这正是 tCPA/tROAS 类产品的语义；
- $\lambda = 1$：效用最大化（经典经济学口径，价值需折算成货币）；

· τ：RoS 约束的门槛，τ 越大要求越严格（tROAS 越高、tCPA 越低）。

> 一个关键认知：广告主几乎从不直接给出 v_j。他们给出的是“预算 + 目标成本”。所以实盘里 $\lambda = 0$ 是常态，约束才是主战场。

1.2 为什么必然是 LP —— 以及 LP 不够用

如果事先知道全部流量及其竞争价，上式对 x_j 是线性的，就是一个线性规划，可以用贪心求解：按“性价比” v_j/p_j 排序，从高到低取，直到预算耗尽。这正是“最优”的定义。

但现实中不知道未来。流量分布随机、竞争对手会随策略调整、转化信号延迟。所以 LP 不能直接解 —— 这正是所有工业级自动出价算法的出发点：

> 把 LP 的最优性条件（对偶）保留下来，只把其中的参数变成在线可调的量。

这个思路把“求一个 m 维的分配方案”降维成“调节几个标量”。下面所有算法，本质上都是在回答：这几个标量怎么定、怎么随时间调。

第 2 章 出价公式：从对偶到实践

2.1 对偶推导

对上式引入拉格朗日乘子：预算约束对应 $\alpha_B \geq 0$，RoS 约束对应 $\alpha_T \geq 0$。对偶问题给出的出价公式（综述式 (7)）为：

$$\boxed{b_j = \frac{v_j + \sum_c \alpha_c \, w_j^c}{\lambda + \sum_c \alpha_c}}$$

其中 w_j^c 是约束 c 对应的“单位价值权重”。取不同约束，就得到不同产品：

场景	参数取法	出价公式	直觉
仅预算约束，效用最大化	$\lambda = 1,\ \alpha_T = 0$	$b_j = \dfrac{v_j}{1 + \alpha_B}$	预算越紧 α_B 越大，出价越保守
仅 tCPA/tROAS	$\lambda = 0,\ \alpha_B = 0$	$b_j = \left(\dfrac{1}{\alpha_T} + \tau\right) v_j$	按价值比例出价
预算 + tCPA 同时	$\lambda = 0$	$b_j = \dfrac{1 + \tau\alpha_T}{\alpha_T + \alpha_B} v_j$	两个乘子分别管“总量”与“成本”

注意三种情形的共同结构：出价永远是价值的正比例缩放（tCPA 情形下额外加了一个常数比例 τ）。这一点的工程含义极大——它意味着 DSP 在线上只需要维护少数几个乘子，而不需要为每条流量单独求解。

2.2 数值验证：对偶出价 = 贪心最优

我用一组 2000 条流量的模拟竞价做了检验（预算 $B = 500$，$\tau = 0.8$），用二分法数值求解 α_B，再对照“按 v/p 贪心截断”的 LP 最优解：

方法	花费	获得价值	说明
对偶出价 $b = v/(1+\alpha_B)$，$\alpha_B = 0.3812$	500.27	2301.28	赢下 72.10% 的流量
贪心截断（LP 最优参照）	500.27	2301.28	取 1442 条

两者价值比 = 1.0000。 这印证了定理 3.1 的结论：只要拿到最优对偶变量，出价公式给出的结果与最优分配完全一致[1]。

> 严谨性注记：定理成立的前提是拍卖是“真实”（truthful）的——即“报出真实价值”是占优策略。二价（GSP/VCG 类）满足，一价不满足。这就是第 3 章要处理的问题。

2.3 工程上真正难的部分：α 从哪来

公式本身不难，难在：α_B, α_T 不是常数。它们随流量分布、竞争激烈度、当天节奏变化。

主流做法是离线估 + 在线调：

1. 离线：用历史日志拟合一个初值（相当于把对偶变量当作一个可学习的参数）；
2. 在线：用反馈控制或在线梯度持续修正。综述给出的经典对偶梯度法（Balseiro & Gur, 2019）为：

$$\alpha_{B,j+1} = \max\left(\alpha_{B,j} + \eta\left(\frac{B}{m} - p_j\right),\, 0\right)$$

其含义非常直观：这一笔花超了平均节奏（$p_j > B/m$）就把 α_B 推高、使后续出价变保守；花少了就放宽。 该算法有 $O(\sqrt{m})$ 的遗憾界。

我做了仿真验证（$m = 40000$，$B = 1000$，取 $\eta \propto 1/\sqrt{m}$）：

阶段	α_B	累计花费	预算进度
起步	0.00000	0.50	0.05%
中段	0.00000	667.53	66.75%
收敛	—	1000.29	100.03%

最终花费 1000.29，严格贴合预算 1000。

> ⚠ 一个必须点明的假设：上面这组数字之所以“贴得这么准”，是因为我按原论文设定加了“预算耗尽即停止出价”的硬约束。如果不加这条，单靠 α 的自校正并不能把花费兜住——我第一次仿真就出现了花超 6.5 倍的情况。 换句话说：对偶梯度负责“节奏”，硬截断负责“兜底”，二者缺一不可。 很多团队把这两件事交给不同系统（出价引擎 + pacing 服务），它们的协同正是下面要讲的关键工程问题。

2.4 双约束不可简单解耦

当预算与 RoS 两个约束同时存在时，如果两个 pacing 系统各自独立运行（“完全解耦的顺序算法”），综述引用的结果显示效果可能很差、且会违反约束；而“最小耦合”（各服务独立运行、但共享少量信息）的方案可以接近完全耦合的最优性能[1]。

工程含义：预算与成本这两套 pacing 不能各调各的。实践中常见做法是让二者共用一个对偶变量更新环，或至少共享消耗速率与达标情况这两个信号。

第 3 章 一价时代的 Bid Shading

3.1 一价为什么改变一切

二价拍卖下，“按真实价值出价”是占优策略——你不需要猜别人。一价拍卖下，赢家付自己报的价，于是：

- 报 v：赢了要付 v，效用为 0；
- 报低一点：可能仍会赢，把钱省下来。

所以最优出价必然低于价值。这个“低于”的比例就是 shading factor。

行业数据：约 96% 的程序化竞价以一价成交（2022 年约 88%）[1]。Google 在 2019 年、Twitter 在 2020 年先后转向一价[2]。

3.2 一个朴素的模型与它的教训

设我方价值 $v = 1$，最高竞争价 h 服从某分布，出价 $b = \alpha v$。则期望效用为

$$U(\alpha) = \Pr[\alpha v > h] \cdot v(1 - \alpha).$$

第一项随 α 上升，第二项随 α 下降 —— 存在一个内点最优。我用对数正态竞争价（$h \sim \mathrm{LN}(0, 0.6)$）做了 2×10^5 次采样：

α	胜率	期望效用
0.30	2.29%	0.01601
0.50	12.45%	0.06225
0.62	20.3%	—
0.70	27.50%	0.08251（最优）
0.80	35.35%	0.07071
1.00	49.80%	0.00000

可以看到：出满价虽然胜率最高（近 50%），但期望效用为零。这正是“赢家的诅咒”的量化形态。

> 注意：最优 α 强烈依赖竞争价的分布，我这里的 0.70 并非普遍常数。文献中常被引用的两个数字是 0.5（鲁棒最坏情形下的经典解，Kasberger & Schlag 2023）与 0.38（均匀价值分布下、考虑分布后可做到比 0.5 更优）。 这里恰恰是“厂商宣传”与“学术结论”最容易脱节的地方：没有任何一个固定百分比是普适的。

3.3 Shading 的算法谱系

按复杂度从低到高（工业界往往同时在用多个层次）：

1. 规则式 shading：按底价、域名、版位设定固定折扣比例。最简单、最易解释，但对新流量失效。
2. 统计/ML 式 shading：用域名、设备、地域、时间、底价、历史胜负等特征，回归估计“结算价区间”，取分位数出价。这是当前 DSP 的主力。
3. 非参数方法：MEOW（KDD 2021）等，用空间高效的非参估计刻画结算价分布[1]。
4. 端到端 / 多任务：MEBS（CIKM 2023）把 shading 与多任务预估联合建模[1]。
5. 先验无关（prior-independent）：最新的理论路线，不对竞争价分布做假设，直接最小化最坏遗憾。

Kumar & Mouchtaki (2026) 的工作值得单独一提[1]：他们证明对每个价值分布都存在一个极小极大最优出价策略（通过解一个 ODE 构造），并指出常见的 uniform shading（一律乘 0.5）会被显著改进——在均匀价值分布下最优 $\alpha = 0.38$，最坏遗憾比 0.5 低约 20%。

3.4 非均匀出价：为什么分段预算能显著提升

一价下的第二个结论：统一乘子次优。如果不同流量簇的竞争强度不同，就应该用不同的 α。

我做了模拟对比（4 个簇，竞争价均值依次递增）：

策略	各簇 α	平均效用
全局统一乘子	0.62（所有簇）	0.07426
分簇非均匀	0.59 / 0.67 / 0.75 / 0.79	0.07676

提升约 3.36%。别小看这个数字——在成熟投放里，3% 的效用提升往往是团队季度级的优化目标。

有意思的是，Google 的实验研究还发现了一个非直觉现象：当非均匀程度（簇数）提高时，一价拍卖的利润和福利都下降，而 GSP 是利润升、福利降，VCG 则几乎不变[1]。这说明“允许买家用更细的颗粒度出价”对卖方未必有利。

第 4 章 预算平滑与双约束协同

4.1 三代 pacing 算法

代际	代表	核心机制	局限
经典控制	PID 及变体	把“效果最大化”转成“按曲线的消耗控制”	流量分布变化大时失灵
规划求解	Online-LP	用历史流量预测未来，反复求解 LP 出价参数	高度依赖未来流量预测精度
学习型	对偶梯度 / RL / 生成式	直接优化序列决策	需要仿真或大量日志；有在离线偏

阿里妈妈公开的叙述印证了这一脉络，并明确指出：PID 阶段“当竞价流量价值分布稳定时能基本满足”——也即PID 适用性是条件性的，不是普适的[1]。

4.2 一个被广泛误解的点

很多人以为 pacing 就是“均速花预算”。但在有成本约束时，最优节奏并不是均匀的：

- 如果前半天流量质量高、后半天质量差，均匀花预算会浪费前半段的优势；
- 如果一批高效流量集中出现，最优策略应当是允许速率波动，只要期末同时满足预算与成本。

这正是对偶变量法的价值：它不规定“每笔花多少”，只规定“这笔在当前代价下的边际价值是否值得”。α_B 是影子价格，速率自然浮出来。

> 工程判据：如果你看到某 DSP 的 pacing 只由“今日已花金额 / 计划金额”驱动，而没有任何价值或成本的边际信号，那它大概率还停留在第一代。

4.3 多通道：给谁预算比给谁目标更重要

广告主往往同时在多个平台投放，而全局的预算与 RoS 约束是跨平台共享的。综述引用的结论非常实用[1]：

- 只调“每通道的 RoS 目标”：总转化可能比全局最优任意差；
- 只调“每通道预算”：可以达到全局最优。

这是一个可以直接用于判断的建议：做跨平台预算分配时，把优化重点放在预算切分上，而不是反复调各个平台的 tCPA/tROAS——后者在理论上可能再努力也达不到最优。

第 5 章 学习型出价：RL 与生成式

5.1 为什么用 RL：参数寻优即序列决策

出价公式把问题降成了“调几个标量”，但这些标量在整个投放周期内应该怎么随时间变化，本身就是序列决策：今天上午调高 α_T，下午的流量与成本都会变。用 MDP 建模：

- 状态：剩余时间、剩余预算、消耗速率、实时 CPC、平均 CPC 等；
- 动作：对出价参数的调整幅度；
- 奖励：该时段的收益（需同时体现约束满足）。

阿里妈妈特别说明了一个建模要点：请求粒度的原始 MDP 在工业界不可行（存储爆炸、转化稀疏延迟），因此主流做法是按时间窗口聚合投放状态——这样既有马尔可夫性，也给日志回流和奖励收集留出时间[1]。

5.2 四代演进与证据

阿里妈妈公开的路线（本报告认为是目前中文世界最完整的工业界自述）：

代际	范式	训练数据来源	报告的效果
一代	经典控制（PID）	业务曲线	分布稳定时可用
二代	LP / Online-LP	历史流量预测	依赖预测精度
三代-A	Simulation RL（SRLB）	自建仿真器	大规模落地，但在离线不一致
三代-B	Offline RL	线上真实日志	用 CQL/IQL 抑制 OOD 高估
三代-C	Online RL（SORL）	与线上交互	解决一致性，需安全探索
四代	生成式（AIGB）	历史轨迹	GMV +4.2%、ROI +5.6%

其中 AIGB 是发表级证据最强的：论文《AIGB: Generative Auto-bidding via Conditional Diffusion Modeling》被 KDD 2024 接收（arXiv:2405.16141），报告在阿里广告平台大规模预算 AB、长周期观测下的 GMV +4.2%、ROI +5.6%[1]。

此外，阿里妈妈 2025 年披露的 Model-based RL（MBRL）新范式也已在其多个场景“完成扩流”，报告大盘覆盖计划 消耗 +3.5% / GMV +4.5%[1]。

5.3 关键学术基石

工作	年份	贡献
Wu et al., Budget Constrained Bidding by Model-free RL（CIKM）	2018	早期在请求粒度用 model-free RL 做出
He et al., A Unified Solution to Constrained Bidding（KDD）	2021	USCB：统一多约束出价公式，成为工
Mou et al., Sustainable Online RL for Auto-bidding（NeurIPS）	2022	SORL：安全在线探索 + V-CQL
Kumar et al., Conservative Q-Learning（CQL）	2020	离线 RL 的保守正则
Kostrikov et al., Implicit Q-Learning（IQL）	2021	用 in-sample 学习避开 OOD 查询
Zhou et al., Off-Policy Safe RL with Real-Time Budget Constraints	2023	带硬预算约束的安全离线 RL
Guo et al., AIGB（KDD）	2024	生成式出价，避免长序列误差累积

> 一个诚实的说明：Google / Meta 的出价算法细节基本不公开。上面这张表里“广泛采用”的判断，主要基于阿里妈妈等公开材料自述其出价形式源自 USCB，以及 Google 综述对这些结构性结论的确认——不是基于对 Google 内部实现的直接证据。

第 6 章 工业界实际部署图景

6.1 三巨头 + 第三方

Google（Ads / DV360）。产品层是 Smart Bidding 家族（tCPA、tROAS、Maximize Clicks / Conversions / Conversion Value）。其研究团队 2024 年的综述与本研究方向完全同构，说明其内部基础是“受约束最优化 + 对偶出价”。2026 年 Google Marketing Live 的表述是 Gemini 正在成为“DV360 真正的操作层”，配套的 Ads Advisor 已 GA[1]。

Meta（Advantage+）。把出价、预算再分配、素材选择打包成默认的自动化方式。官方口径为 Advantage+ 带来 22% ROAS 提升，年化运行率达 200 亿美元以上。但需要警惕：有第三方增量测试发现 Advantage+ 的实际增量转化仅为平台归因报告的 17% 左右[1]。这是一个重要的反面证据——平台内归因与真实增量不是一回事。

The Trade Desk（Koa）。以“一价拍卖历史成交价建模”为核心，公开报道其 Koa 引擎相对人工优化有 20–30% 的性能提升；2026 年 8 月的 Kokai Zuma 更新声称平均 CPA 改善 32%[1]。值得注意的是 TTD 的定位：其代理产品明确“只给建议、不自主出价”，主张“架构重于自主”。

阿里妈妈。中文世界披露最完整：四代演进 + USCB 出价形式 + Offline/Online RL + AIGB 生成式，且有论文级证据。

第三方 DSP / buy-side（如 Moloco、Criteo、RTB House 等）通常以“深度学习预估 + 自定义出价规则”为主，公开细节少于上述几家。

6.2 能力矩阵（据公开材料）

维度	Google	Meta	TTD	阿里妈妈
出价形式	受约束 LP 对偶	未公开	一价成交价建模	USCB 对偶公式
预算 pacing	有（未公开细节）	有	有	PID→LP→RL→生成式
Bid shading	市场层面处理	N/A（自营库存）	核心能力	MEBS 等多任务方案
RL 出价	研究层面确认	未公开	未公开	已论文+线上
生成式出价	未公开	未公开	未公开	AIGB（KDD 2024）
自主程度	全生命周期自动化	高度自主（默认）	仅建议	平台侧自动
证据等级	A/B	B/C	C	A（论文）/B（博客）

第 7 章 主流方案的共性判断

综合以上，给出七条可操作的结论：

1. 骨架统一，实现分化。 所有人都在解同一个受约束 LP，区别在于约束形式（是否多约束、是否多坑）、对偶变量怎么估、预估模型多准。判断一个 DSP 水平高低，看这三件事，而不是看它宣传什么“算法”。

2. 价值预估的精度往往比出价算法本身更重要。 出价公式只是把 v_j 与 α 组合起来；如果 v_j（eCPM / pCVR）不准，再精妙的对偶也救不回来。这是行业里最不性感、但最决定成败的部分。

3. 一价下必须有 shading，且不能是固定百分比。 我的仿真显示，固定乘子的最优值强依赖竞争价分布；分簇（非均匀）出价能再带来约 3.4% 的效用提升。任何“我们统一打 X 折”的方案都值得质疑。

4. 对偶变量负责节奏，硬截断负责兜底。 我的两次仿真（不加/加硬约束）分别是花超 6.5 倍与精确贴预算——这个对比说明了工程实现的必要性，也说明只读论文是危险的。

5. 预算与成本两套 pacing 不可解耦。 完全解耦会既掉效果又违反约束；最小耦合可接近最优。

6. 跨平台时，优先切预算，而不是反复调目标。 理论上只调各通道 RoS 目标可能任意次优，而只调预算可达到全局最优。

7. 平台内归因 ≠ 真实增量。 Meta 案例中被第三方测出的 17% 增量差异提醒：评估 DSP 效果必须做独立的增量实验（geo test / 对照holdout），不能只看平台报表。

第 8 章 前沿与未解问题

1. 隐私与信号衰退。第三方 cookie 退场后，跨站特征减少，v_j 的估计精度下降。DSP 的共同应对是转向第一方数据、上下文信号与服务端集成。但值得注意的是：Meta 的 Advantage+ 本身就是 2022 年应对 iOS 14.5 的产物[1]——隐私压力是自动化加速的推手，而非阻力。

2. Agentic 化的真实含义。2026 年三大平台都在推代理。但 TTD 明确选择“只建议”，Meta 选择“默认自主”。这个分歧的核心不是技术，而是责任归属：谁为一次糟糕的自动决策负责。Forrester 甚至预测 2026 年代理行业 15% 的岗位会消失——这提示读者，出价自动化正在从“优化工具”变成“组织变革”。

3. 增量性与评估污染。当平台同时负责投放与归因，评估就存在结构性利益冲突。这是目前最被低估的问题。

4. 多约束与公平性。真实广告主往往同时有预算、CPA、ROI、曝光量等多个约束。多约束下的出价公式虽有解，但高维对偶变量的在线稳定性仍是开放问题。此外小广告主在大广告主主导的竞价环境中效果偏差，是已发表的研究方向（KDD 2023 的 fairness-aware bidding）。

5. 跨平台最优。已证明“只调预算可达全局最优”，但如何在信息不共享的多平台间实现仍是难题。

6. 理论 vs 实证的张力。综述明确指出，PoA（无政府代价）是最坏情形分析，而真实市场的均衡福利通常好得多；同时实证发现“更好的自动出价反而降低拍卖效率”[1]。理论与实践的落差本身就是一个值得研究的问题。

附录 A 复现说明

本报告的数值实验均可在标准 Python + NumPy 环境下复现，口径如下：

实验	设置	关键结论
对偶出价 vs 贪心	$n=2000$，$v,p\sim$ 对数正态，$B=500$，$\tau=0.8$，二分求 α_B	价值比 1.0000
折扣乘子扫描	$h\sim \mathrm{LN}(0,0.6)$，2×10^5 采样	最优 $\alpha=0.70$，出满价效用为 0
非均匀出价	4 簇，竞争价均值递增	提升 3.36%
对偶梯度 pacing	$m=40000$，$B=1000$，$\eta\propto 1/\sqrt{m}$，加硬截断	花费 1000.29/1000

说明：上述均为合成数据上的机制演示，用于验证公式结构是否正确，不代表任何真实平台的效果。

附录 B 算法速查

场景	出价形式	需在线调节的量
仅预算（效用最大化）	$b=v/(1+\alpha_B)$	α_B（1 个标量）
仅 tCPA/tROAS	$b=(1/\alpha_T+\tau)v$	α_T
预算 + tCPA	$b=\frac{1+\tau\alpha_T}{\alpha_T+\alpha_B}v$	α_B,α_T
多约束	$b=\frac{v+\sum_c \alpha_c w_j^c}{\lambda+\sum_c \alpha_c}$	每约束 1 个
一价 shading	$b=\alpha\cdot b_{\text{base}}$	α（分簇则每簇 1 个）

附录 C 术语中英对照

中文	英文	含义
需求方平台	DSP	代表广告主采购流量的系统
实时竞价	RTB	按请求逐个竞价的机制
自动出价	auto-bidding	系统代广告主决定出价
出价折扣	bid shading	一价下压低出价的策略
预算平滑	budget pacing	控制预算消耗节奏
对偶变量	dual variable	LP 对偶问题中的影子价格
目标转化成本	tCPA	广告主设定的成本上限
目标广告回报	tROAS	广告主设定的回报下限
一价/二价拍卖	FPA / SPA	赢家付自己的价 / 付第二高价
在离线不一致	sim-to-real gap	仿真训练与线上环境的分布偏差
无政府代价	PoA	均衡效率与最优效率之比

参考文献（核心 20 条）

1. G. Aggarwal, A. Badanidiyuru, S. R. Balseiro, 等 24 人. Auto-bidding and Auctions in Online Advertising: A Survey. arXiv:2408.07685, 2024.
2. Y. He, X. Chen, D. Wu, 等. A Unified Solution to Constrained Bidding in Online Display Advertising. KDD 2021.
3. J. Guo, Y. Huo, Z. Zhang, 等. AIGB: Generative Auto-bidding via Conditional Diffusion Modeling. KDD 2024, arXiv:2405.16141.
4. Z. Mou, Y. Huo, R. Bai, 等. Sustainable Online RL for Auto-bidding. NeurIPS 2022.
5. S. Balseiro, Y. Gur. Learning in Repeated Auctions with Budgets: Regret Minimization and Equilibrium. Management Science, 2019.
6. D. Wu, X. Chen, X. Yang, 等. Budget Constrained Bidding by Model-free RL in Display Advertising. CIKM 2018.
7. D. Gligorijevic, T. Zhou, B. Shetty, 等. Bid Shading in the Brave New World of First-Price Auctions. CIKM 2020.
8. W. Zhang, B. Kitts, Y. Han, 等. MEOW: A Space-Efficient Nonparametric Bid Shading Algorithm. KDD 2021.
9. Z. Gong, L. Niu, Y. Zhao, 等. MEBS: Multi-task End-to-end Bid Shading for Multi-slot Display Advertising. CIKM 2023.
10. R. Kumar, O. Mouchtaki. Prior-Independent Bidding Strategies for First-Price Auctions. arXiv:2502.09907, 2026.
11. A. Kumar, A. Zhou, G. Tucker, S. Levine. Conservative Q-Learning for Offline RL. NeurIPS 2020, arXiv:2006.04779.
12. I. Kostrikov, A. Nair, S. Levine. Offline RL with Implicit Q-Learning. arXiv:2110.06169, 2021.
13. R. Ai, C. Wang, 等. No-regret Learning in Repeated First-Price Auctions with Budget Constraints. arXiv:2205.14572, 2022.
14. G. Aggarwal, G. Fikioris, M. Zhao. No-Regret Algorithms in non-Truthful Auctions with Budget and ROI Constraints. arXiv:2404.09832, 2024.
15. Q. Lin, B. Tang, Z. Wu, 等. Off-Policy Safe RL with Real-Time Budget Constraints. arXiv:2306.00603, 2023.
16. H. Zhang, L. Niu, Z. Zheng, 等. A Personalized Automated Bidding Framework for Fairness-aware Online Advertising. KDD 2023.

17. 阿里妈妈技术. 强化学习在广告自动出价场景的大规模落地实践. 2024-01.

18. 阿里妈妈技术. Model-based RL 自动出价算法的演进之路. 2025-01.

19. MediaPost. Trade Desk Goes Agentic, Simplifies Programmatic Buying — Just Ask Koa. 2026-08-27.

20. PPC Land. Meta’s AI advertising gamble: Brand control versus algorithmic efficiency. 2025-10.

说明

- 本报告完成于 2026 年 10 月 26 日，公开材料检索截至当日。
- 证据分级：A = 同行评审论文/官方技术报告；B = 官方博客/技术文档；C = 行业媒体/厂商资料；D = 本报告的推断。
- 所有厂商宣称的效果数字均标注来源与等级，未经独立复现的不作因果结论。
- 第 6 章中关于 Google / Meta 内部实现的部分，属于基于其公开研究成果的合理推断，非直接证据。
- 报告不构成任何平台选型或投放策略建议。

脚注

[1] 同上，Theorem 3.1。

[2] 同上 §3.2，引 Balseiro et al. (2023b)。

[3] BidsCube, What Is Bid Shading and How It Works in First-Price Auctions, 2026-09. 引 Digital Applied 2026 统计。

[4] 见 [1] §3.3 及其脚注。

[5] Zhang, Kitts, Han 等. MEOW: A Space-Efficient Nonparametric Bid Shading Algorithm. KDD 2021.

[6] Gong, Niu, Zhao 等. MEBS: Multi-task End-to-end Bid Shading for Multi-slot Display Advertising. CIKM 2023.

[7] Kumar & Mouchtaki. Prior-Independent Bidding Strategies for First-Price Auctions. arXiv:2502.09907, 2026.

[8] 见 [1] §6.3，引 Deng et al. (2024c)。

[9] 阿里妈妈技术. 强化学习在广告自动出价场景的大规模落地实践. 2024-01.

[10] 见 [1] §6.2.1，引 Deng et al. (2023a)。

[11] Guo, Huo, Zhang 等. AIGB: Generative Auto-bidding via Diffusion Modeling. KDD 2024. arXiv:2405.16141.

[12] 阿里妈妈技术. Model-based RL 自动出价算法的演进之路. 2025-01.

[13] AgentMarketCap. The Agentic Advertising Stack. 2026-07；及 MediaPost 对 TTD 的报道（下文）。

[14] PPC Land. Meta’s AI advertising gamble: Brand control versus algorithmic efficiency. 2025-10.

[15] MediaPost. Trade Desk Goes Agentic, Simplifies Programmatic Buying — Just Ask Koa. 2026-08-27.

[16] Google Research. Autobidder’s Dilemma: Why Better Autobidders Lead to Worse Auction Efficiency.